ADP 15회 실기 문제

문항을 읽고 분석 과정·근거·수치·시각화를 함께 제시하세요.
성명 _____ 작성일 _____

본 문서는 첨부된 공개 복원 자료를 문제지 형식으로 재편집한 학습용 자료입니다. 원문에 모호한 표현이 있어도 문항 본문에는 유지했으며, 해석은 별도 풀이 노트북에 있습니다.

1번 | 데이터 확인 및 전처리

철강데이터 종속변수 : target

데이터 출처 : https://www.kaggle.com/uciml/faulty-steel-plates

자료 미리보기: 첫 5행 (일부 열 표시)

X_Minimum	X_Maximum	Y_Minimum	Y_Maximum	Pixels_Areas	X_Perimeter
42	50	270900	270944	267	17
645	651	2538079	2538108	108	10
829	835	1553913	1553931	71	8
853	860	369370	369415	176	13
1289	1306	498078	498335	2409	60

1.1	EDA와 시각화 및 통계량 제시
1.2	변수 선택(VIF), 파생변수 생성, 데이터 분할(train/test(20%)) ,시각화와 통계량을 제시하시오
1.3	종속변수들중 “1”인지 아닌지 판단하려한다. 종속변수를 1과 1이 아닌 값으로 치환하고 로지스틱 회귀 분석을 실시하라. confusionMatrix를 확인 및 cut off value 정하여라
1.4	종속변수(y)를 다항(7 class)인 상태에서 SVM을 포함하여 3가지 알고리즘으로 평가하라
1.5	종속변수를 제외한 나머지 데이터를 바탕으로 군집분석을 실시하고 최적의 군집수와 군집 레이블을 구하여라. 군집레이블을 추가한 데이터를 1-4에서 만든 모델중 가장 성능이 좋았던 하나의 모델에 다시 학습하여 F1-score를 비교하라

2번 | 데이터 확인 및 전처리

데이터 출처 : 직접제작

데이터 설명 : 2050년 1년동안의 5유형(A,B,C,D,E)의 전력사용량을 나타낸다. 각유형의 전력사용량은 1분마다 갱신되며 그 값은 누적된다.

6시간이 지나면(00:00, 06:00, 12:00, 18:00시에) 전력사용량은 0으로 초기화 된다.

problem2_usage.csv : 6시간 간격의 총 전력사용량의 데이터이다. timestamp순서는 섞여있다. 6시간 간격의 특정 시간대(마지막시각 '05:59','11:59','17:59','23:59')의 전력 총합을 나타낸다.

problem2_usage_history.csv : 1분간격의 A,B,C,D,E 유형의 소비 누적 전력을 나타낸다. 같은 6시간간격의 시간대의 데이터는 같은 "6hour_index"값을 가진다. 00:00, 06:00, 12:00, 18:00시에는 5유형의 전력은 초기화 된다.

두 사용량 파일의 총합을 비교할 때 부동소수점 오류가 날수 있다. 파이썬의 경우 round(4)를 취하여 해결한다.

problem2_avg_tem.csv : 2050년 1년동안 일자별 평균 온도를 나타낸다.

2-1	usage의 총사용량을 아래와 같은 모양으로 연월별 총합으로 계산하여 CSV 파일로 작성하시오 일자별 총사용량은 누적사용량이 갱신되기 직전의 최대값들의 합으로 계산한다. ['05:59','11:59','17:59','23:59'] 시간대의 A,B,C,D,E의 컬럼별 총합이 각 유형의 일일 사용량이다

원문 제시 자료

date	A	B	C	D	E
2050-01	25437.7174	29524.6880	26325.6721	26787.3492	24378.5654
2050-02	22587.0869	27962.4256	21188.7855	23261.3711	24636.3545
2050-03	28677.4668	23861.8640	23680.9832	26945.8322	27807.9163
2050-04	24420.2217	27322.6681	26299.6225	27226.8895	24303.1778
2050-05	27028.2178	25173.2009	30392.3686	28374.1651	26624.1963
2050-06	23862.7219	25125.0544	26334.0899	23571.0519	32754.0932
2050-07	26248.3486	25135.6214	28735.8080	31315.0381	27056.5461
2050-08	29171.1880	26769.4921	20612.4922	27432.0263	23671.4985
2050-09	26819.4225	31334.2996	25562.1052	22301.2104	25674.1093
2050-10	26625.0033	31567.2153	27878.8204	26277.2181	29153.3849
2050-11	24428.1793	25954.0829	26846.9570	25095.3070	21936.6133
2050-12	28772.9185	28289.4406	23454.8789	28347.7543	24565.2342

2-2	가로축을 요일(일~월) 세로축을 평균 전력사용량으로 하는 그래프를 그려라. 각 유형별로 색을 다르게 표현하여 5개의 line plot을 그리며 범례를 표시하라
2-3	요일별 각 유형의 평균 전력 사용량 간에 연관성이 있는지 검정하라
2-4	일자(매일)마다 각 유형의 전력사용량의 합을 데이터프레임으로 구하고 일자 데이터에서의 유형별 온도와의 상관계수를 각각 구하여라