ADP 17회 실기 문제

문항을 읽고 분석 과정·근거·수치·시각화를 함께 제시하세요.
성명 _____ 작성일 _____

본 문서는 첨부된 공개 복원 자료를 문제지 형식으로 재편집한 학습용 자료입니다. 원문에 모호한 표현이 있어도 문항 본문에는 유지했으며, 해석은 별도 풀이 노트북에 있습니다.

1번 | 주택 가격

데이터 설명 : 집과 관련된 여러 수치들과 집의 가격, log1p 정규화된 price 컬럼 예측 하기

데이터 출처 : https://www.kaggle.com/c/house-prices-advanced-regression-techniques/data?select=train.csv 일부 전처리

data Url : https://raw.githubusercontent.com/Datamanim/datarepo/main/adp/p3/problem1.csv

자료 미리보기: 첫 5행 (일부 열 표시)

Id	LotArea	LotFrontage	YearBuilt	1stFlrSF	2ndFlrSF
1	8450	65	2003	856	854
2	9600	80	1976	1262	0
3	11250	68	2001	920	866
4	9550	60	1915	961	756
5	14260	84	2000	1145	1053

1-1	데이터 EDA 수행 후, 분석가 입장에서 의미있는 탐색 시각화 및 통계량 제시
1-2	Train,Valid,Test set으로 분할 및 시각화 제시
1-3	2차 교호작용항 까지 고려한 회귀분석 수행 및 변수 선택 과정 제시
1-4	벌점, 앙상블을 포함하여 모형에 적합한 기계학습 모델 3가지를 제시하라 (평가지표는 MSE, MAPE, R2 모두 확인할 것)

2번 | 코로나19 국가별 데이터

데이터 설명 : 코로나19에 대한 나라별 데이터로 모델링 진행

데이터 출처 : https://www.kaggle.com/imdevskp/corona-virus-report 일부 후처리

data Url : https://raw.githubusercontent.com/Datamanim/datarepo/main/adp/p3/problem2.csv

location : 지역명 / date : 일자 / total_cases : 누적 확인자 / total_deaths : 누적 사망자 / new_tests : 검사자 / population : 인구 / new_vaccinations : 백신 접종자

자료 미리보기: 첫 5행 (일부 열 표시)

location	date	total_cases	total_deaths	new_tests	population
Afghanistan	2020-02-24	5	NaN	NaN	39835428
Afghanistan	2020-02-25	5	NaN	NaN	39835428
Afghanistan	2020-02-26	5	NaN	NaN	39835428
Afghanistan	2020-02-27	5	NaN	NaN	39835428
Afghanistan	2020-02-28	5	NaN	NaN	39835428

2-1

마지막 일자를 기준으로 인구 대비 확진자 비율이 높은 상위 5개 국가를 구하여라
상위 5개 국가별로 누적 확진자, 일일 확진자, 누적 사망자, 일일 사망자, 그래프, 범례를 이용해서 가독성 있게 만들어라

2-2

코로나 위험지수를 직접 만들고 그 위험지수에 대한 설명을 적고 위험지수가 높은 국가들 10개를 선정해서 시각화

2-3

한국의 코로나 신규 확진자 예측해라(선형 시계열모델 + 비선형시계열 각각 한개씩 만들어라)
선형시계열 - arma 비선형 시계열 - arima

3번 | 설문조사 데이터

데이터 출처 : 자체 제작

data Url : https://raw.githubusercontent.com/Datamanim/datarepo/main/adp/p3/problem3.csv

데이터 설명 : A ~ D까지의 그룹에게 각각 같은 설문조사를 하여 1-1,1-2,1-3…5-1,5-4 인 설문지를 푼 것이다. 문항은 영역별로 나뉘어 있고, 영역은 크게 5개이다(1~5). 각 영역의 세부문항은 4개씩 존재한다 (1-1,1-2,1-3,1-4 ~).

이 때 중간에 반대 문항이 들어가 있다. 예를 들어 1-1 문제가 “나는 시간약속을 잘 지킨다.”라는 문제라면 1-3의 문제는 “나는 시간약속을 잘 지키지 않는다.” 라는 역문제로 구성 되어있다. 각 영역의 3번문항의 1번문항의 역문제이다. 모든 답변은 5점 척도이다. 문제를 풀기전 모든 역문항의 경우 점수를 변환(6점을 빼서) 작업이 필요하다.

자료 미리보기: 첫 5행 (일부 열 표시)

userid	group	Q1-1	Q1-2	Q1-3	Q1-4	Q2-1	Q2-2
0	A	5	2	1	2	4	5
1	A	2	2	3	3	4	3
2	A	1	3	4	4	2	1
3	A	3	3	4	2	2	4
4	A	3	1	2	3	4	3

3-1	역문항을 변환 한 후 각 그룹(A~D)의 영역(Q1~Q5)별 응답의 평균, 표준편차, 왜도, 첨도를 구하라. (각 통계량 별로 4x5 dataframe 생성)
3-2	그룹별로 Q1-1문항의 차이가 존재하는지 anova분석을 시행하라
3-3	탐색적 요인분석을 수행하고 결과를 시각화 하라