분석전문가(ADP) 실기

모의고사 14회 | 고객센터 문의 횟수와 이탈

학습 안내

대상 독자: 데이터 분석 지식은 있으나 이 산업·업무를 처음 접하는 학습자입니다. 각 대문항의 배경과 변수 사전을 먼저 읽으십시오.

본 자료는 공식 기출 원문·공식 배점·정답이 아닌 학습용 모의입니다. 기존 자료·후기·창작 합성 여부와 상세 출처는 각 폴더 안내를 따릅니다.

읽는 순서: 상황과 관측 단위 → 변수 사전 → 고정 분석 조건 → 수행 과제 → 별도 실행 풀이·해설. 대문항 간 자료는 지문에서 결합을 요구하지 않으면 별개입니다.

대문항	자료	문항 수
1. 회귀 설계와 조건별 개선	regression.csv	6
2. 이진 사건 예측과 샘플링	classification.csv	5
3. 미래 수요와 시간순 검증	timeseries.csv	4

답안 작성: 방법 선택 근거·가정·실제 수치·판정·상황 결론을 구분합니다. 통계적 비기각을 가정의 증명으로 쓰지 않고, 예측 점수와 업무 의사결정을 구분합니다.

자료 사용: 목표·식별자·시간·그룹의 역할을 구분합니다. 학습용 전처리·선택·sampling·튜닝은 학습/CV 안에서 수행하고 최종 평가 자료는 선택에 사용하지 않습니다.

15문항·100점·권장 180분: 회귀 36점 / 분류 40점 / 시계열 24점. 후보·분할·시드는 실행설정.json과 아래 지문을 따릅니다.

1. 회귀 설계와 조건별 개선 | 자료 이해

상황과 관측 단위

문의 횟수는 같은 하루 동안 고객센터에 접수된 건수입니다. 이탈은 고객이 이용을 중단한 사건입니다.

회귀 한 행은 동일 노출의 하루, 분류 한 행은 별도 고객 사건 관측입니다. 회귀 행은 이 연습에서 독립으로 취급합니다. 정수 횟수의 평균·분산 관계와 이탈 검출을 구분합니다. 횟수 자료라고 자동으로 시계열 모형이 되는 것은 아닙니다.

제공 자료: data/regression.csv

열	의미·역할
id	관측 식별자; 예측 입력에서 제외
target	일별 문의 횟수; 예측할 반응
users	사용자 규모의 편차 지수; 원 측정값/표본 표준화 아님
release_change	서비스 변경 정도의 편차 지수; 원 측정값/표본 표준화 아님
usage	이용 강도의 편차 지수; 원 측정값/표본 표준화 아님
complexity	처리 복잡도의 편차 지수; 원 측정값/표본 표준화 아님

고정 분석 조건

같은 하루 노출의 문의 횟수는 0을 포함하는 비음수 정수다. 평균-분산 관계와 과산포를 검토하고 연속 반응 모형의 한계를 설명한다. regression.csv의240행은 서로 독립인 개체/배치을 가정한 고정 합성 자료다. 목표 target의 단위는 일별 문의 횟수이며 id는 식별자다. 입력은 users, release_change, usage, complexity다. 입력은 고정 업무 기준 대비 편차 지수이므로 음수가 가능하며 표본 전체에서 미리 추정한 표준화 값이 아니다. 시드 20270009로 학습70%/최종평가30% 분할하고 학습 shuffled3-fold를 사용한다. 후보 선택 기준은 동일 원반응 단위 CV R^2 최대다. 기본 대치·표준화·선형 모형, VIF5, AIC/BIC 후진 선택과 정수 횟수 반응의 Poisson log-mean 후보를 사전 지정한다. 모든 학습 통계·변수선택·행 처리는 폴드 안에서 적합한다. 유의수준은5%이며 반복 진단은 탐색적 개별검정으로 보고한다. 최종평가로 후보나 가정을 골라서는 안 된다.

1. 회귀 설계와 조건별 개선 | 수행 과제

1-1 [6점]
관측 단위·목표 척도·예측 시점과 입력의 역할을 정리하고 결측·분포·공선성 후보를 탐색하시오.
지정 분할의 원행 위치를 남기고 전체 자료 대치나 식별자 입력이 왜 부적절한지 설명하시오.

1-2 [6점]
기본 전처리와 선형 기준 모형을 학습에 적합하고 학습/CV R^2, 계수 t 검정·전체 F 검정·AIC·BIC를 제시하시오.
계수·설명력·일반화 성능의 의미와 기본 추론 가정을 구분하시오.
최종평가는 아직 사용하지 마시오.

1-3 [6점]
기준 모형의 선형 사양·잔차 정규성·등분산성과 관측 설계에 맞는 독립성/자기상관을 진단하시오.
가설·통계량·p값·가정·판정과 잔차/분위수/영향도 그림을 보고하시오.
VIF와 Cook 영향도의 대상을 구분하고 이상 관측을 자동으로 오류라고 단정하지 마시오.

1-4 [6점]
동일 학습 행·동일 원반응에서 AIC와 BIC로 후진 변수선택을 수행하고 제거 경로·남은 특성을 비교하시오.
VIF 제거와의 차이, 서로 다른 y변환·관측 행의 정보량을 직접 비교하는 오류, 변수선택 후 추론의 한계를 설명하시오.

1-5 [6점]
사전 지정 전처리·변수선택·대안 모형을 학습 CV 내부에서 튜닝하시오.
후보별 원단위 CV R^2·선택 파라미터·실패 여부와 분할을 보고하고 하나를 선택하시오.
특히 정수 횟수 반응의 Poisson log-mean 후보의 적용 조건과 처리 단위를 설명하시오.

1-6 [6점]
선택 이후에만 기준/선택 모형을 동일 최종평가 행으로 평가하여 R^2·RMSE·MAE와 R^2 차이를 보고하시오.
진단 전후 또는 대안 분포의 적절한 잔차·분산·영향도 근거를 해석하고, 개선이 없거나 가정 위반이 남아도 그대로 보고하시오.
동일 노출의 횟수와 평균=분산 조건을 점검한다.
과산포·과도한0을 검토하며 서로 다른 노출에는 알려진 log exposure가 필요하다.
pseudo R^2와 원 단위 보류 R^2는 별개다.

2. 이진 사건 예측과 샘플링 | 자료 이해

상황과 관측 단위

문의 횟수는 같은 하루 동안 고객센터에 접수된 건수입니다. 이탈은 고객이 이용을 중단한 사건입니다.

한 행은 회귀와 별도로 생성한 독립 사건 관측입니다. 실제 사건을 놓치는 경우와 잘못 경보하는 경우의 비용을 구분합니다.

제공 자료: data/classification.csv

열	의미·역할
id	관측 식별자
target	1=고객 이탈, 0=해당 사건 없음
c1	사건 전에 측정한 가상 연속 위험 신호 1
c2	사건 전에 측정한 가상 연속 위험 신호 2
c3	사건 전에 측정한 가상 연속 위험 신호 3
c4	사건 전에 측정한 가상 연속 위험 신호 4

고정 분석 조건

classification.csv는 별도 독립360관측의 합성 자료이며 target=1은 고객 이탈이다. c1~c4는 사건 발생 전의 수치 위험 신호, id는 식별자다. 층화 학습70%/최종평가30% 분할(시드20270009), 학습3-fold ROC AUC를 사용한다. 무보완과 random_under를 비교하되 학습 폴드 안의 대치→표준화→VIF5→샘플링→L2 로지스틱 예측모형을 사용한다. C 후보는0.1·1·10이고 GridSearchCV 전수비교로 튜닝한다. 운영 임계값0.5는 사전 고정이며 false-negative 비용12·false-positive 비용1이다. 별도로 원 학습 분포의 비벌점 이진 GLM을 설명용 적합하되 예측모형과 같은 추정량이라 주장하지 않는다.

2. 이진 사건 예측과 샘플링 | 수행 과제

2-1 [8점]
목표 사건·양성 라벨·클래스 불균형과 층화 분할을 정리하시오.
데이터 분리 전에 샘플을 보완하면 발생하는 누출과 최종평가의 자연 발생률을 유지해야 하는 이유를 설명하시오.

2-2 [8점]
지정 탐색과 샘플링 모듈을 연결하고 동일 학습 폴드에서 무보완/보완 후보를 비교하시오.
파라미터·CV ROC AUC·선택 후보·폴드 위치를 제시하고 검증/최종평가에는 샘플링을 수행하지 않았음을 확인하시오.

2-3 [8점]
원 학습 분포의 설명용 이진 모형에서 계수·오즈비·구간·z 검정·우도 비교·AIC/BIC를 보고하시오.
첫 선택 특성의 제곱항 추가에 대한 log-odds 사양 검토를 수행하고 가설·자유도·p값·한계를 제시하시오.
OLS 잔차 정규성·보통 R^2·t/F를 일괄 적용하지 마시오.

2-4 [8점]
CV 선택 뒤 최종평가의 ROC 곡선·ROC AUC·precision-recall·평균정밀도·확률 보정 그림과 Brier 점수, 고정0.5 혼동행렬을 제시하시오.
불균형에서 정확도 하나만으로 판단하는 한계를 설명하시오.

2-5 [8점]
사전 지정 비용과 임계값으로 최종평가 오분류 비용을 계산하고 운영 의사결정을 제안하시오.
AUC·확률 보정·분류 임계값의 차이, 샘플링에 따른 발생률 변화와 별도 학습 검증 필요성을 설명하시오.
최종평가를 보고 새 임계값을 최적화하지 마시오.

3. 미래 수요와 시간순 검증 | 자료 이해

상황과 관측 단위

문의 횟수는 같은 하루 동안 고객센터에 접수된 건수입니다. 이탈은 고객이 이용을 중단한 사건입니다.

한 행은 하루입니다. 앞 두 자료와 결합하지 않는 별도의 140일 합성 시계열입니다. 앞으로 7일의 값을 예측하고 단순 기준 예측과 같은 날짜에서 비교합니다.

제공 자료: data/timeseries.csv

열	의미·역할
date	중복 없는 등간격 날짜
target	일별 수요/사용량의 학습용 연속 지표; 회귀·분류 target과 별개

고정 분석 조건

timeseries.csv는 고객센터 문의 횟수와 이탈의 별도140일 합성 수요/사용 기록이다. date는 중복 없는 등간격 일자, target은 별도의 연속 수요 지표이며 회귀/분류의 target과 대상·단위가 다르다. 공변량 예측은 사용하지 않는다. 마지막7일은 최종 미래 평가로 봉인한다. 학습의 마지막14일을 두 구간으로 나눠 각각 직전까지 확장 학습하고7일씩 예측한다. 차수 후보(0,0,0)·(1,0,0)를 rolling 평균 RMSE로 선택한다. 비계절 ARIMA를 사용하며 기준은 직전 값 반복이다. 예측구간 신뢰수준95%이고 최적화 최대100회다. 회귀/분류 자료와는 다른 과제다.

3. 미래 수요와 시간순 검증 | 수행 과제

3-1 [6점]
시간 간격·순서·목표·예측 horizon을 확인하고 과거/최종 미래를 나누시오.
학습의 정상성 진단 가설·통계량·p값과 추세·계절성의 한계를 설명하시오.
무작위 CV가 부적절한 이유를 서술하시오.

3-2 [6점]
지정 expanding rolling 검증을 구현하여 후보별 RMSE·MAE·수렴/실패, 각 과거/검증 구간을 제시하고 차수를 선택하시오.
최종 미래값을 차수·전처리 선택에 사용하지 마시오.

3-3 [6점]
선택 모형의 학습 AIC·BIC와 초기화 구간을 제외한 잔차 자기상관 진단을 보고하시오.
추정한 AR/MA 자유도를 반영하고 가설·통계량·p값·판정·해석을 제시하시오.
차분이나 우도 정의가 다른 모형의 정보량 단순 비교를 경계하시오.

3-4 [6점]
선택 모형과 지정 naive의 동일 미래7일 RMSE·MAE·R^2·MASE를 비교하고 예측·관측·조건부 예측구간을 시각화하시오.
MASE의 학습 분모, 음의 보류 R^2 가능성, 차수 선택 불확실성을 구간이 모두 반영하지 않는 한계를 설명하시오.