분석전문가(ADP) 실기

모의고사 16회 | 지역 출산 지표·영화평·생존 분류

학습 안내

대상 독자: 데이터 분석 지식은 있으나 이 산업·업무를 처음 접하는 학습자입니다. 각 대문항의 배경과 변수 사전을 먼저 읽으십시오.

본 자료는 공식 기출 원문·공식 배점·정답이 아닌 학습용 모의입니다. 기존 자료·후기·창작 합성 여부와 상세 출처는 각 폴더 안내를 따릅니다.

읽는 순서: 상황과 관측 단위 → 변수 사전 → 고정 분석 조건 → 수행 과제 → 별도 실행 풀이·해설. 대문항 간 자료는 지문에서 결합을 요구하지 않으면 별개입니다.

대문항	자료	문항 수
1. 지역 출산 지표의 설명과 예측	regression.csv	4
2. 학습용 영화평의 품사·빈도·감성	reviews.csv + lexicon.csv	4
3. 대피 생존 분류와 제출	classification.csv + submission.csv	4

답안 작성: 방법 선택 근거·가정·실제 수치·판정·상황 결론을 구분합니다. 통계적 비기각을 가정의 증명으로 쓰지 않고, 예측 점수와 업무 의사결정을 구분합니다.

자료 사용: 목표·식별자·시간·그룹의 역할을 구분합니다. 학습용 전처리·선택·sampling·튜닝은 학습/CV 안에서 수행하고 최종 평가 자료는 선택에 사용하지 않습니다.

12문항·100점·권장240분. 대문항별 배점은 지문을 따릅니다. 후기의 유형을 참고했으며 조건·합성 자료·평가 설계는 독립 창작입니다.

1. 지역 출산 지표의 설명과 예측 | 자료 이해

상황과 관측 단위

관측의 조건과 결과 관계를 설명하고 새 관측의 결과를 예측한다.

한 행은 서로 독립인 관측이다. x1=주거비 편차지수, x2=지원 접근성 점수, x3=고용 안정 점수, target=합성 출산 지표(표준화 지수 아님). 추론의 조건과 예측 성능을 구분해 보고한다.

제공 자료: data/regression.csv | 후기 유형 참고·조건/자료/배점은 창작

열	의미·역할
id	독립 관측 식별자; 입력 제외
x1	주거비 편차지수
x2	지원 접근성 점수
x3	고용 안정 점수
group	관측 집단 범주 A/B; 처치 아님
target	합성 출산 지표(표준화 지수 아님)

고정 분석 조건

x1=주거비 편차지수, x2=지원 접근성 점수, x3=고용 안정 점수, target=합성 출산 지표(표준화 지수 아님). 240행. x1에 결측이 있다. id를 제외하고 중앙값 대치 후 수치형은 학습 평균/표준편차(ddof0)로 표준화하고 집단은 one-hot(drop first) 처리한 뒤 OLS를 적합한다. x1,x2,x3의 단순/전체모형 비교는 같은 학습 행이다. random_state=20281016로 학습70%/평가30%를 나누고 학습3-fold shuffled CV를 사용한다. 다항식 차수2, RF60나무 깊이3/5는 사전 후보다.

1. 지역 출산 지표의 설명과 예측 | 수행 과제

1-1 [10점]
관측 단위·입력·반응·누출 위험과 결측을 정리하고 지정한 학습/평가 원행을 기록하시오.
학습 입력의 분포와 변수 관계를 ax 두 개에 제시하시오.

1-2 [10점]
학습 자료에 지정 OLS를 적합하고 계수 t 검정·전체 F 검정·R^2·수정 R^2·AIC·BIC를 보고하시오.
단순모형과 전체모형의 비교에서 같은 행과 반응을 유지하시오.

1-3 [10점]
RESET·잔차 정규성·Breusch-Pagan·VIF·Cook을 계산하고 Q-Q·잔차/적합값을 subplots로 제시하시오.
명시하지 않은 관측 제거를 수행하지 말고 진단별 한계를 설명하시오.

1-4 [10점]
동일 학습 CV에서 기준 선형모형·다항식·랜덤포레스트를 RMSE로 비교해 하나를 선택하시오.
봉인한 같은 평가 행에서 원단위 RMSE·MAE·R^2와 관측-예측 그림을 제시하고 기준 대비 차이를 해석하시오.

2. 학습용 영화평의 품사·빈도·감성 | 자료 이해

상황과 관측 단위

상영관별 의견을 단어와 간단한 사전 점수로 요약한다.

한 행은 영화평 한 건이다. 품사는 제공 사전의 표시에만 한정된다. 반복 빈도와 문서빈도, 미등록 단어의 누락을 구분한다.

제공 자료: data/reviews.csv + lexicon.csv | 후기 유형 참고·조건/자료/배점은 창작

열	의미·역할
reviews.csv / id	문서 식별자
reviews.csv / group	가상 상영관 A/B
reviews.csv / text	통제 어휘로 만든 영어 문장; 공백 포함
lexicon.csv / token	등록 영어 단어
lexicon.csv / pos	제공 사전의 품사 NOUN/ADJ/STOP
lexicon.csv / polarity	형용사 극성 -1/0/1; 다른 품사는 결측

고정 분석 조건

영문 합성 영화평60건, id·group·text가 있다. lexicon의 token은 원형, pos는 NOUN/ADJ/STOP, polarity는 형용사에만 -1/0/1이다. 정규식 [a-z]+로 소문자 토큰화하고 ADJ만 빈도에 포함한다. 미등록 토큰은 보존해 일치율을 계산한다. 부정 범위·문맥 품사는 추론하지 않는다.

2. 학습용 영화평의 품사·빈도·감성 | 수행 과제

2-1 [5점]
문서 식별자·집단·공백 문서·중복을 확인하고 소문자화·영문 토큰 분리를 수행하시오.
제공 사전의 품사·극성·불용어 역할을 설명하시오.

2-2 [5점]
지정 품사만 남기고 단어별 출현 횟수·문서빈도를 구하시오.
상위 단어 빈도를 ax에 그리고 둘의 분모가 다른 이유를 설명하시오.

2-3 [5점]
문서별 사전 일치율과 형용사 극성 평균을 계산하시오.
일치 단어가 없는 문서의 점수는 결측으로 유지하고 미등록·부정 표현에 대한 규칙의 한계를 설명하시오.

2-4 [5점]
문서별 결과와 집단별 유효 문서 수·평균 점수를 저장하고 그림으로 비교하시오.
명사 중심 과제에서도 형용사 기반 감성은 별도 보충으로 구분하고 집단의 실제 만족도로 일반화하지 마시오.

3. 대피 생존 분류와 제출 | 자료 이해

상황과 관측 단위

서비스 운영팀이 미리 관측한 특성으로 결과 클래스를 예측한다. 생존은 합성 구조물 대피 상황의 결과다.

한 행은 서로 독립인 가상 이용자다. 별도 제출 파일의 target은 제공하지 않는다. 평가와 제출 예측을 분리하고 분류 확률의 한계를 검토한다.

제공 자료: data/classification.csv + submission.csv | 후기 유형 참고·조건/자료/배점은 창작

열	의미·역할
id	학습/제출 관측 식별자; 입력 제외
x1	사건 전에 측정한 수치 지표1
x2	사건 전에 측정한 수치 지표2
x3	사건 전에 측정한 수치 지표3
group	사건 전에 알려진 서비스 종류 A/B/C
target	학습 자료에만 있는 정수 클래스; 제출 자료에는 없음

고정 분석 조건

학습360행과 정답 없는 제출24행은 별개다. target은 0=생존하지 못함,1=생존. id는 입력 제외. random_state=20281016로 층화70/30, 학습3-fold shuffled CV. 수치 중앙값 대치·표준화, group 최빈 대치·one-hot(handle_unknown=ignore)를 CV 안에서 적합한다. 후보는 LR C=0.3/1, RF60나무 깊이3/5, GB40단계 깊이2, LR/RF/GB 동일 가중 soft voting이다. 각 후보의 CV 학습 폴드에서만 RandomOverSampler를 적용한다.

3. 대피 생존 분류와 제출 | 수행 과제

3-1 [10점]
사건/클래스 정의·시점·식별자·결측·클래스 비율을 정리하고 층화 학습/평가 분리 원행을 제시하시오.
범주별 목표 분포를 ax에 표시하시오.

3-2 [10점]
지정한 여러 분류기와 soft voting을 같은 학습 CV로 비교하시오.
학습 폴드 내부 전처리·지정 sampling·GridSearchCV를 사용하고 macro F1로 선택한 설정과 CV 결과를 기록하시오.

3-3 [10점]
선택 후보를 전체 학습 자료에 적합하고 평가 혼동행렬·클래스별 재현율·macro F1·클래스 순서를 제시하시오.
이진 또는 one-vs-rest ROC와 AUC를 ax별로 그리고 확률 보정·임계값 한계를 설명하시오.

3-4 [10점]
라벨 없는 별도 제출 자료를 예측해 id·prediction 열의 submission.csv를 저장하시오.
행 순서·식별자·라벨 정의역·중복·누락을 검사하고 평가 점수와 실제 제출 자료의 성능을 구분하시오.