분석전문가(ADP) 실기

응용 모의 제2회 | 물류 배송비와 파손 위험

학습 안내

대상 독자: 데이터 분석 지식은 있으나 이 산업·업무를 처음 접하는 학습자입니다. 각 대문항의 배경과 변수 사전을 먼저 읽으십시오.

본 자료는 공식 기출 원문·공식 배점·정답이 아닌 학습용 모의입니다. 기존 자료·후기·창작 합성 여부와 상세 출처는 각 폴더 안내를 따릅니다.

읽는 순서: 상황과 관측 단위 → 변수 사전 → 고정 분석 조건 → 수행 과제 → 별도 실행 풀이·해설. 대문항 간 자료는 지문에서 결합을 요구하지 않으면 별개입니다.

대문항	자료	문항 수
1. 회귀 설계와 조건별 개선	regression.csv	6
2. 이진 사건 예측과 샘플링	classification.csv	5
3. 미래 수요와 시간순 검증	timeseries.csv	4

답안 작성: 방법 선택 근거·가정·실제 수치·판정·상황 결론을 구분합니다. 통계적 비기각을 가정의 증명으로 쓰지 않고, 예측 점수와 업무 의사결정을 구분합니다.

자료 사용: 목표·식별자·시간·그룹의 역할을 구분합니다. 학습용 전처리·선택·sampling·튜닝은 학습/CV 안에서 수행하고 최종 평가 자료는 선택에 사용하지 않습니다.

15문항·100점·권장 180분: 회귀 36점 / 분류 40점 / 시계열 24점. 후보·분할·시드는 실행설정.json과 아래 지문을 따릅니다.

1. 회귀 설계와 조건별 개선 | 자료 이해

상황과 관측 단위

배송비는 화물을 운송하는 비용이며, 파손은 운송 중 물품이 손상된 사건입니다.

회귀 한 행은 배송 건, 분류 한 행은 별도의 배송 위험 관측입니다. 큰 비용의 예측 오차와 파손 누락 위험을 각각 평가합니다.

제공 자료: data/regression.csv

열	의미·역할
id	관측 식별자; 예측 입력에서 제외
target	배송비(천원); 예측할 반응
weight	화물 무게의 편차 지수; 원 측정값/표본 표준화 아님
distance	배송 거리의 편차 지수; 원 측정값/표본 표준화 아님
volume	화물 부피의 편차 지수; 원 측정값/표본 표준화 아님
handling	취급 난이도의 편차 지수; 원 측정값/표본 표준화 아님

고정 분석 조건

배송비는 양수이며 큰 비용에서 변동 폭이 크다. 원 비용과 변환 반응의 설명력을 혼동하지 말고 원 비용으로 역변환한 예측을 비교한다. regression.csv의240행은 서로 독립인 개체/배치을 가정한 고정 합성 자료다. 목표 target의 단위는 배송비(천원)이며 id는 식별자다. 입력은 weight, distance, volume, handling다. 입력은 고정 업무 기준 대비 편차 지수이므로 음수가 가능하며 표본 전체에서 미리 추정한 표준화 값이 아니다. 시드 20270002로 학습70%/최종평가30% 분할하고 학습 shuffled3-fold를 사용한다. 후보 선택 기준은 동일 원반응 단위 CV R^2 최대다. 기본 대치·표준화·선형 모형, VIF5, AIC/BIC 후진 선택과 양수 목표의 log 변환과 학습 잔차 smearing 후보를 사전 지정한다. 모든 학습 통계·변수선택·행 처리는 폴드 안에서 적합한다. 유의수준은5%이며 반복 진단은 탐색적 개별검정으로 보고한다. 최종평가로 후보나 가정을 골라서는 안 된다.

1. 회귀 설계와 조건별 개선 | 수행 과제

1-1 [6점]
관측 단위·목표 척도·예측 시점과 입력의 역할을 정리하고 결측·분포·공선성 후보를 탐색하시오.
지정 분할의 원행 위치를 남기고 전체 자료 대치나 식별자 입력이 왜 부적절한지 설명하시오.

1-2 [6점]
기본 전처리와 선형 기준 모형을 학습에 적합하고 학습/CV R^2, 계수 t 검정·전체 F 검정·AIC·BIC를 제시하시오.
계수·설명력·일반화 성능의 의미와 기본 추론 가정을 구분하시오.
최종평가는 아직 사용하지 마시오.

1-3 [6점]
기준 모형의 선형 사양·잔차 정규성·등분산성과 관측 설계에 맞는 독립성/자기상관을 진단하시오.
가설·통계량·p값·가정·판정과 잔차/분위수/영향도 그림을 보고하시오.
VIF와 Cook 영향도의 대상을 구분하고 이상 관측을 자동으로 오류라고 단정하지 마시오.

1-4 [6점]
동일 학습 행·동일 원반응에서 AIC와 BIC로 후진 변수선택을 수행하고 제거 경로·남은 특성을 비교하시오.
VIF 제거와의 차이, 서로 다른 y변환·관측 행의 정보량을 직접 비교하는 오류, 변수선택 후 추론의 한계를 설명하시오.

1-5 [6점]
사전 지정 전처리·변수선택·대안 모형을 학습 CV 내부에서 튜닝하시오.
후보별 원단위 CV R^2·선택 파라미터·실패 여부와 분할을 보고하고 하나를 선택하시오.
특히 양수 목표의 log 변환과 학습 잔차 smearing 후보의 적용 조건과 처리 단위를 설명하시오.

1-6 [6점]
선택 이후에만 기준/선택 모형을 동일 최종평가 행으로 평가하여 R^2·RMSE·MAE와 R^2 차이를 보고하시오.
진단 전후 또는 대안 분포의 적절한 잔차·분산·영향도 근거를 해석하고, 개선이 없거나 가정 위반이 남아도 그대로 보고하시오.
log(y)의 잔차 진단과 원 y 단위 예측 성능은 서로 다른 좌표계다.
단순 exp(예측)은 원 반응 조건부 평균이 아니며 학습 잔차 보정도 오차 사양에 의존한다.

2. 이진 사건 예측과 샘플링 | 자료 이해

상황과 관측 단위

배송비는 화물을 운송하는 비용이며, 파손은 운송 중 물품이 손상된 사건입니다.

한 행은 회귀와 별도로 생성한 독립 사건 관측입니다. 실제 사건을 놓치는 경우와 잘못 경보하는 경우의 비용을 구분합니다.

제공 자료: data/classification.csv

열	의미·역할
id	관측 식별자
target	1=파손 발생, 0=해당 사건 없음
c1	사건 전에 측정한 가상 연속 위험 신호 1
c2	사건 전에 측정한 가상 연속 위험 신호 2
c3	사건 전에 측정한 가상 연속 위험 신호 3
c4	사건 전에 측정한 가상 연속 위험 신호 4

고정 분석 조건

classification.csv는 별도 독립360관측의 합성 자료이며 target=1은 파손 발생이다. c1~c4는 사건 발생 전의 수치 위험 신호, id는 식별자다. 층화 학습70%/최종평가30% 분할(시드20270002), 학습3-fold ROC AUC를 사용한다. 무보완과 smote를 비교하되 학습 폴드 안의 대치→표준화→VIF5→샘플링→L2 로지스틱 예측모형을 사용한다. C 후보는0.1·1·10이고 Optuna6 trials, 시드고정로 튜닝한다. 운영 임계값0.5는 사전 고정이며 false-negative 비용5·false-positive 비용1이다. 별도로 원 학습 분포의 비벌점 이진 GLM을 설명용 적합하되 예측모형과 같은 추정량이라 주장하지 않는다.

2. 이진 사건 예측과 샘플링 | 수행 과제

2-1 [8점]
목표 사건·양성 라벨·클래스 불균형과 층화 분할을 정리하시오.
데이터 분리 전에 샘플을 보완하면 발생하는 누출과 최종평가의 자연 발생률을 유지해야 하는 이유를 설명하시오.

2-2 [8점]
지정 탐색과 샘플링 모듈을 연결하고 동일 학습 폴드에서 무보완/보완 후보를 비교하시오.
파라미터·CV ROC AUC·선택 후보·폴드 위치를 제시하고 검증/최종평가에는 샘플링을 수행하지 않았음을 확인하시오.

2-3 [8점]
원 학습 분포의 설명용 이진 모형에서 계수·오즈비·구간·z 검정·우도 비교·AIC/BIC를 보고하시오.
첫 선택 특성의 제곱항 추가에 대한 log-odds 사양 검토를 수행하고 가설·자유도·p값·한계를 제시하시오.
OLS 잔차 정규성·보통 R^2·t/F를 일괄 적용하지 마시오.

2-4 [8점]
CV 선택 뒤 최종평가의 ROC 곡선·ROC AUC·precision-recall·평균정밀도·확률 보정 그림과 Brier 점수, 고정0.5 혼동행렬을 제시하시오.
불균형에서 정확도 하나만으로 판단하는 한계를 설명하시오.

2-5 [8점]
사전 지정 비용과 임계값으로 최종평가 오분류 비용을 계산하고 운영 의사결정을 제안하시오.
AUC·확률 보정·분류 임계값의 차이, 샘플링에 따른 발생률 변화와 별도 학습 검증 필요성을 설명하시오.
최종평가를 보고 새 임계값을 최적화하지 마시오.

3. 미래 수요와 시간순 검증 | 자료 이해

상황과 관측 단위

배송비는 화물을 운송하는 비용이며, 파손은 운송 중 물품이 손상된 사건입니다.

한 행은 하루입니다. 앞 두 자료와 결합하지 않는 별도의 140일 합성 시계열입니다. 앞으로 7일의 값을 예측하고 단순 기준 예측과 같은 날짜에서 비교합니다.

제공 자료: data/timeseries.csv

열	의미·역할
date	중복 없는 등간격 날짜
target	일별 수요/사용량의 학습용 연속 지표; 회귀·분류 target과 별개

고정 분석 조건

timeseries.csv는 물류 배송비와 파손 위험의 별도140일 합성 수요/사용 기록이다. date는 중복 없는 등간격 일자, target은 별도의 연속 수요 지표이며 회귀/분류의 target과 대상·단위가 다르다. 공변량 예측은 사용하지 않는다. 마지막7일은 최종 미래 평가로 봉인한다. 학습의 마지막14일을 두 구간으로 나눠 각각 직전까지 확장 학습하고7일씩 예측한다. 차수 후보(0,0,0)·(1,0,0)를 rolling 평균 RMSE로 선택한다. 비계절 ARIMA를 사용하며 기준은 직전 값 반복이다. 예측구간 신뢰수준95%이고 최적화 최대100회다. 회귀/분류 자료와는 다른 과제다.

3. 미래 수요와 시간순 검증 | 수행 과제

3-1 [6점]
시간 간격·순서·목표·예측 horizon을 확인하고 과거/최종 미래를 나누시오.
학습의 정상성 진단 가설·통계량·p값과 추세·계절성의 한계를 설명하시오.
무작위 CV가 부적절한 이유를 서술하시오.

3-2 [6점]
지정 expanding rolling 검증을 구현하여 후보별 RMSE·MAE·수렴/실패, 각 과거/검증 구간을 제시하고 차수를 선택하시오.
최종 미래값을 차수·전처리 선택에 사용하지 마시오.

3-3 [6점]
선택 모형의 학습 AIC·BIC와 초기화 구간을 제외한 잔차 자기상관 진단을 보고하시오.
추정한 AR/MA 자유도를 반영하고 가설·통계량·p값·판정·해석을 제시하시오.
차분이나 우도 정의가 다른 모형의 정보량 단순 비교를 경계하시오.

3-4 [6점]
선택 모형과 지정 naive의 동일 미래7일 RMSE·MAE·R^2·MASE를 비교하고 예측·관측·조건부 예측구간을 시각화하시오.
MASE의 학습 분모, 음의 보류 R^2 가능성, 차수 선택 불확실성을 구간이 모두 반영하지 않는 한계를 설명하시오.