분석전문가(ADP) 실기

응용 모의 제4회 | 공정 수율과 불량 검출

성명	작성일	배점
	____년 __월 __일	100점 / 15문항

응시 안내

기존 공문서형·상황형 학습 자료와 같은 구성의 창작 종합 모의입니다. 공식 기출 원문·공식 배점·정답이 아닙니다. 권장시간180분, 회귀36점·분류40점·시계열24점입니다. 제공 CSV와 실행설정.json의 후보·분할·시드를 따르십시오. 데이터의 생성 원리를 분석 전에 정답으로 가정하지 마십시오.

검정은 방법 선정 근거·가정·가설·통계량·자유도·p값·판정·상황 결론을 구분합니다. 전처리·변수선택·샘플링·튜닝은 학습/CV 안에서만 수행하고 최종평가는 봉인합니다. 정보량·R^2·p값·예측구간의 의미를 혼동하지 마십시오. 개선이 없거나 가정이 남아도 실제 결과를 보고합니다.

자료: 고정 합성 관측이며 실제 기업·고객 데이터가 아닙니다. 기법의 기술 근거·범위는 동봉 출처및설계.md와 저장소 명세를 참고하십시오. 각 대문항은 별도 자료입니다.

1. 회귀 설계와 조건별 개선

자료: data/regression.csv

부하가 큰 배치에서 수율 오차 변동 폭이 커질 수 있다. 알려진 분산은 없으며 학습 잔차에서 추정하는 분산 모형은 불확실성을 가진다. regression.csv의240행은 서로 독립인 개체/배치을 가정한 고정 합성 자료다. 목표 target의 단위는 수율 점수이며 id는 식별자다. 입력은 load, pressure, temperature, speed다. 입력은 고정 업무 기준 대비 편차 지수이므로 음수가 가능하며 표본 전체에서 미리 추정한 표준화 값이 아니다. 시드20270004로 학습70%/최종평가30% 분할하고 학습 shuffled3-fold를 사용한다. 후보 선택 기준은 동일 원반응 단위 CV R^2 최대다. 기본 대치·표준화·선형 모형, VIF5, AIC/BIC 후진 선택과 학습 분산 추정의 가중 회귀1·2회 후보를 사전 지정한다. 모든 학습 통계·변수선택·행 처리는 폴드 안에서 적합한다. 유의수준은5%이며 반복 진단은 탐색적 개별검정으로 보고한다. 최종평가로 후보나 가정을 골라서는 안 된다.

1-1. [6점] 관측 단위·목표 척도·예측 시점과 입력의 역할을 정리하고 결측·분포·공선성 후보를 탐색하시오. 지정 분할의 원행 위치를 남기고 전체 자료 대치나 식별자 입력이 왜 부적절한지 설명하시오.

1-2. [6점] 기본 전처리와 선형 기준 모형을 학습에 적합하고 학습/CV R^2, 계수 t 검정·전체 F 검정·AIC·BIC를 제시하시오. 계수·설명력·일반화 성능의 의미와 기본 추론 가정을 구분하시오. 최종평가는 아직 사용하지 마시오.

1-3. [6점] 기준 모형의 선형 사양·잔차 정규성·등분산성과 관측 설계에 맞는 독립성/자기상관을 진단하시오. 가설·통계량·p값·가정·판정과 잔차/분위수/영향도 그림을 보고하시오. VIF와 Cook 영향도의 대상을 구분하고 이상 관측을 자동으로 오류라고 단정하지 마시오.

1-4. [6점] 동일 학습 행·동일 원반응에서 AIC와 BIC로 후진 변수선택을 수행하고 제거 경로·남은 특성을 비교하시오. VIF 제거와의 차이, 서로 다른 y변환·관측 행의 정보량을 직접 비교하는 오류, 변수선택 후 추론의 한계를 설명하시오.

1-5. [6점] 사전 지정 전처리·변수선택·대안 모형을 학습 CV 내부에서 튜닝하시오. 후보별 원단위 CV R^2·선택 파라미터·실패 여부와 분할을 보고하고 하나를 선택하시오. 특히 학습 분산 추정의 가중 회귀1·2회 후보의 적용 조건과 처리 단위를 설명하시오.

1-6. [6점] 선택 이후에만 기준/선택 모형을 동일 최종평가 행으로 평가하여 R^2·RMSE·MAE와 R^2 차이를 보고하시오. 진단 전후 또는 대안 분포의 적절한 잔차·분산·영향도 근거를 해석하고, 개선이 없거나 가정 위반이 남아도 그대로 보고하시오. 가중치는 참 분산을 알고 지정한 값이 아니다. 추정 역분산·가중 잔차·원단위 R^2를 구분하고 조건부 표준오차가 분산 추정 불확실성을 반영하지 않음을 밝힌다.

2. 이진 사건 예측과 샘플링

자료: data/classification.csv

classification.csv는 별도 독립360관측의 합성 자료이며 target=1은 불량 발생이다. c1~c4는 사건 발생 전의 수치 위험 신호, id는 식별자다. 층화 학습70%/최종평가30% 분할(시드20270004), 학습3-fold ROC AUC를 사용한다. 무보완과 smote를 비교하되 학습 폴드 안의 대치→표준화→VIF5→샘플링→L2 로지스틱 예측모형을 사용한다. C 후보는0.1·1·10이고 GridSearchCV 전수비교로 튜닝한다. 운영 임계값0.5는 사전 고정이며 false-negative 비용7·false-positive 비용1이다. 별도로 원 학습 분포의 비벌점 이진 GLM을 설명용 적합하되 예측모형과 같은 추정량이라 주장하지 않는다.

2-1. [8점] 목표 사건·양성 라벨·클래스 불균형과 층화 분할을 정리하시오. 데이터 분리 전에 샘플을 보완하면 발생하는 누출과 최종평가의 자연 발생률을 유지해야 하는 이유를 설명하시오.

2-2. [8점] 지정 탐색과 샘플링 모듈을 연결하고 동일 학습 폴드에서 무보완/보완 후보를 비교하시오. 파라미터·CV ROC AUC·선택 후보·폴드 위치를 제시하고 검증/최종평가에는 샘플링을 수행하지 않았음을 확인하시오.

2-3. [8점] 원 학습 분포의 설명용 이진 모형에서 계수·오즈비·구간·z 검정·우도 비교·AIC/BIC를 보고하시오. 첫 선택 특성의 제곱항 추가에 대한 log-odds 사양 검토를 수행하고 가설·자유도·p값·한계를 제시하시오. OLS 잔차 정규성·보통 R^2·t/F를 일괄 적용하지 마시오.

2-4. [8점] CV 선택 뒤 최종평가의 ROC 곡선·ROC AUC·precision-recall·평균정밀도·확률 보정 그림과 Brier 점수, 고정0.5 혼동행렬을 제시하시오. 불균형에서 정확도 하나만으로 판단하는 한계를 설명하시오.

2-5. [8점] 사전 지정 비용과 임계값으로 최종평가 오분류 비용을 계산하고 운영 의사결정을 제안하시오. AUC·확률 보정·분류 임계값의 차이, 샘플링에 따른 발생률 변화와 별도 학습 검증 필요성을 설명하시오. 최종평가를 보고 새 임계값을 최적화하지 마시오.

3. 미래 수요와 시간순 검증

자료: data/timeseries.csv

timeseries.csv는 공정 수율의 별도140일 합성 수요/사용 기록이다. date는 중복 없는 등간격 일자, target은 원 단위 관측량이며 공변량 예측은 사용하지 않는다. 마지막7일은 최종 미래 평가로 봉인한다. 학습의 마지막14일을 두 구간으로 나눠 각각 직전까지 확장 학습하고7일씩 예측한다. 차수 후보(0,0,0)·(1,0,0)를 rolling 평균 RMSE로 선택한다. 비계절 ARIMA를 사용하며 기준은 직전 값 반복이다. 예측구간 신뢰수준95%이고 최적화 최대100회다. 회귀/분류 자료와는 다른 과제다.

3-1. [6점] 시간 간격·순서·목표·예측 horizon을 확인하고 과거/최종 미래를 나누시오. 학습의 정상성 진단 가설·통계량·p값과 추세·계절성의 한계를 설명하시오. 무작위 CV가 부적절한 이유를 서술하시오.

3-2. [6점] 지정 expanding rolling 검증을 구현하여 후보별 RMSE·MAE·수렴/실패, 각 과거/검증 구간을 제시하고 차수를 선택하시오. 최종 미래값을 차수·전처리 선택에 사용하지 마시오.

3-3. [6점] 선택 모형의 학습 AIC·BIC와 초기화 구간을 제외한 잔차 자기상관 진단을 보고하시오. 추정한 AR/MA 자유도를 반영하고 가설·통계량·p값·판정·해석을 제시하시오. 차분이나 우도 정의가 다른 모형의 정보량 단순 비교를 경계하시오.

3-4. [6점] 선택 모형과 지정 naive의 동일 미래7일 RMSE·MAE·R^2·MASE를 비교하고 예측·관측·조건부 예측구간을 시각화하시오. MASE의 학습 분모, 음의 보류 R^2 가능성, 차수 선택 불확실성을 구간이 모두 반영하지 않는 한계를 설명하시오.