ADP 20회 실기 문제

hits 8 / 691

Attention

캐글에 업로드된 다른 분들 코드 보러가기

문제오류, 코드오류 댓글로 피드백주세요

Attention

1번

날씨 온도 예측, 종속변수 :actual(최고온도)

데이터 출처 : https://towardsdatascience.com/random-forest-in-python-24d0893d51c0

데이터 경로 : /kaggle/input/adp-kr-p2/problem1.csv

temp_1 : 전날 최고온도

temp_2 : 전전날 최고온도

friend : 친구의 예측온도

1-1번

데이터 확인 및 전처리

- 데이터 EDA 수행
- 결측치를 확인하고 처리 방안에 대해 논의하라
- 데이터 분할 방법 설명
- 최종 데이터셋이 적절함을 주장하라

▶ Show code cell content

🔔 1-2번

Random Forest 모델 적합 및 검증

- Random Forest 학습 및 예측 결과 해석
- 예측 결과 검정 해석, 중요변수 도출
- 변수 중요성 분석 및 그래프 출력

▶ Show code cell content

🔔 1-3번

SVM(Support Vector Machine) 모델 적합 및 검증

- svm 학습 및 예측 결과 해석
- 예측 결과 검정 해석, 중요변수 도출
- 변수 중요성 분석 및 그래프 출력

▶ Show code cell source

```
svm r2_score :  0.8138036782618503
learning time  0.008105278015136719
svm은 변수 중요도를 따로 추출 할 수 없다. r2_score의 경우 RandomForest에 비해 낮다
```

🔔 1-4번

모델 비교 및 향후 개선 방향 도출

- Random Forest, SVM 모델의 결과 비교 후 최종 모델 선택
- 두 모델의 장단점 분석, 추후 운영 관점에서 어떤 모델을 선택할 것인가?
- 모델링 관련 추후 개선 방향 제시

▶ Show code cell source

	learning time	r2_score
RandomForest	0.134737	0.839919
Svm	0.008105	0.813804

파라미터 튜닝을 제외한 기본모델의 경우 모델학습시간은 랜덤포레스트가 svm에 비해 더 오래 걸린다.
test셋에 대한 모델 r2score는 랜덤포레스트가 더 높다.
모델 학습시간을 중점둔다면 svm이 더 유리하다. 하지만 랜덤포레스트의 경우 변수중요도를 확인 할 수
최종적으로는 랜덤포레스트를 선택한다.

Attention

2번

5분간격의 가구별 전력 사용량의 데이터

데이터 출처 : 자체생성

데이터 경로 : https://raw.githubusercontent.com/Datamanim/datarepo/main/adp/p2/problem2.csv

```
import matplotlib.pyplot as plt
ttt= pd.read_csv('https://raw.githubusercontent.com/Datamanim/datarepo/ma
```

2-1번

데이터 전처리

각 가구의 15분간격의 전력량의 합을 구하고 해당데이터를 바탕으로 총 5개의 군집으로 군집화를 진행한 후 아래의 그림과 같은 형태로 출력하라.

군집화를 위한 데이터 구성의 이유를 설명하라

(군집 방식에 따라 Cluster컬럼의 값은 달라질수 있음)

	houseCode	date	power consumption sum	Cluster
0	house_00	2050-01-01 00:00:00	136.249952	1
1	house_00	2050-01-01 00:15:00	98.283387	1
2	house_00	2050-01-01 00:30:00	53.967679	1
3	house_00	2050-01-01 00:45:00	204.821270	3
4	house_00	2050-01-01 01:00:00	150.760786	3
...	...	...	...	...
133915	house_44	2050-01-31 22:45:00	334.675717	4
133916	house_44	2050-01-31 23:00:00	463.419892	2
133917	house_44	2050-01-31 23:15:00	369.930740	4
133918	house_44	2050-01-31 23:30:00	237.713030	0
133919	house_44	2050-01-31 23:45:00	184.888439	3

133920 rows × 4 columns

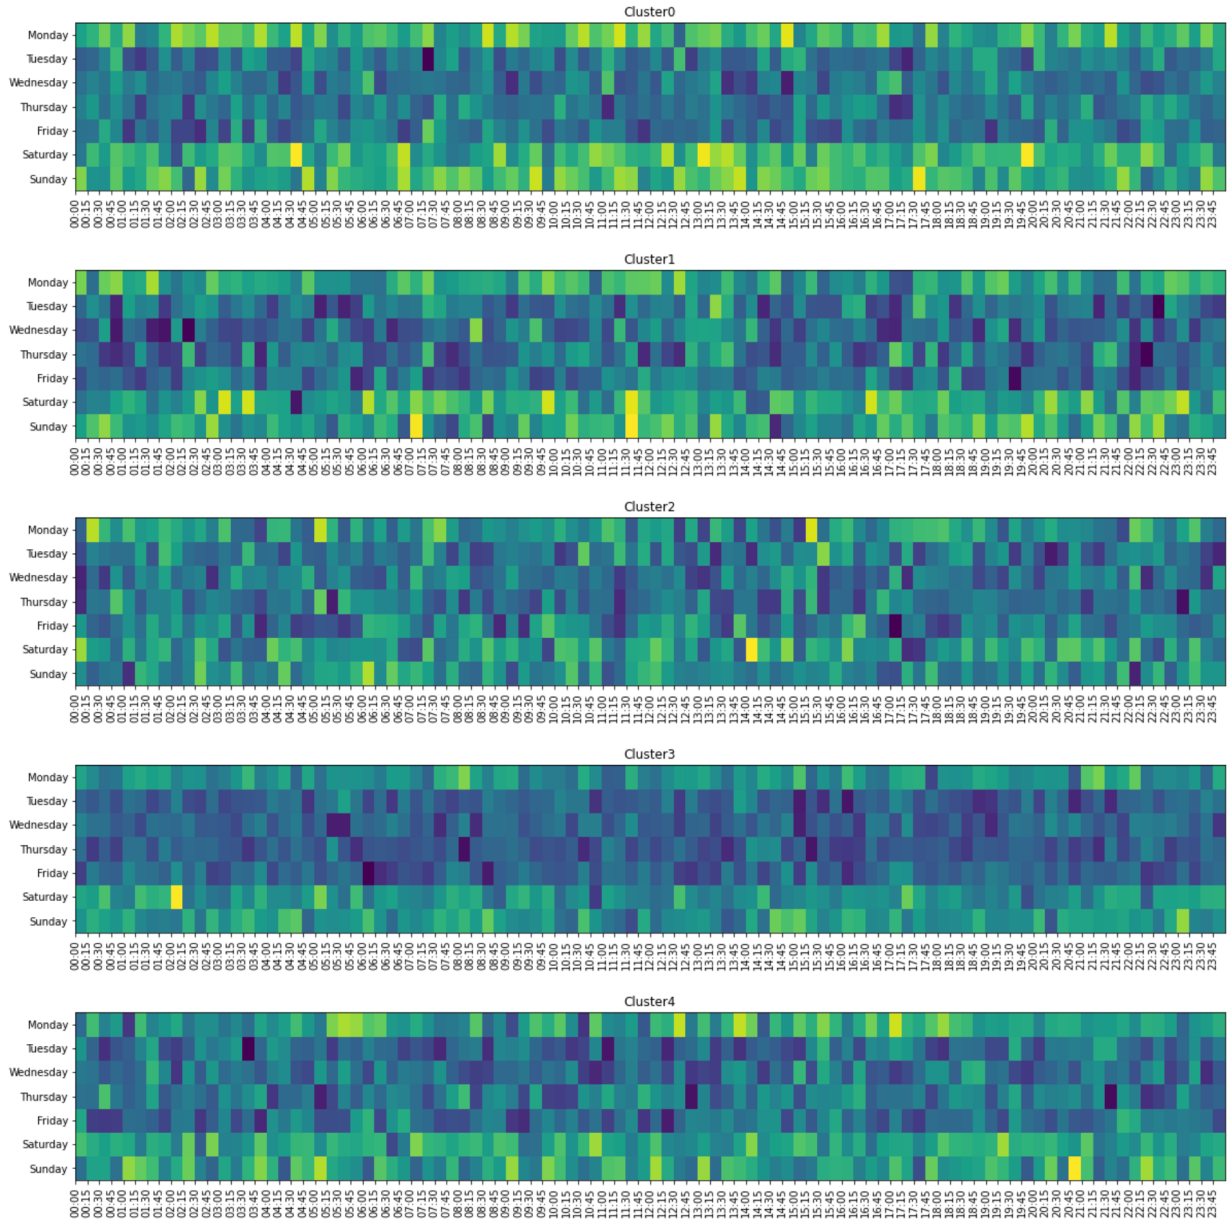
▶ Show code cell content

2-2번

히트맵 시각화

2-1의 데이터를 바탕으로 각 군집의 요일, 15분간격별 전력사용량의 합을 구한 후 아래와 같이 시각화 하여라

(수치는 동일하지 않을 수 있음 2-1의 데이터가 정확하게 아래와 같은 이미지로 변환 됐는지 주로 확인)



▶ Show code cell content

Attention

3번

태양광 데이터

데이터 출처 : https://www.kaggle.com/cheedcheed/california-renewable-production-20102018

데이터 경로 : https://raw.githubusercontent.com/Datamanim/datarepo/main/adp/p2/problem3.csv

예측 변수 :SOLAR PV

```
import pandas as pd
df= pd.read_csv('https://raw.githubusercontent.com/Datamanim/datarepo/mai
df.head()
```

	TIMESTAMP	BIOGAS	BIOMASS	GEOTHERMAL	Hour	SMALL HYDRO	SOLAR
0	2012-11-26 00:00:00	208.0	354.0	926.0	1.0	208.0	NaN
1	2012-11-26 01:00:00	207.0	354.0	927.0	2.0	207.0	NaN
2	2012-11-26 02:00:00	208.0	353.0	927.0	3.0	208.0	NaN
3	2012-11-26 03:00:00	208.0	350.0	927.0	4.0	209.0	NaN
4	2012-11-26 04:00:00	209.0	352.0	927.0	5.0	209.0	NaN

🔔 **3-1번**

데이터셋 분할 및 결과 검증

- 데이터셋 7:3 분할
- 데이터 전처리 및 예측 모델 생성
- 모델 성능 검증 : RMSE, R제곱, 정확도(아래 방식으로 연산)로 구하여라
- 정확도의 경우 실제값>예측값인 경우 (1-예측값/실제값), 실제값<예측값인 경우 (1-실제값/예측값)으로 하고 이것들을 평균낸 후 1에서 뺀값으로 한다.
  분수식의 분모가 0인 경우의 정확도는 0.5로 취급한다.
- 최종 결과 제출 : 소수점 3째자리 반올림

▶ Show code cell content