분석전문가(ADP) 실기

33회 후기 유형 연습 · 9문항

성명	작성일	자료 구분
	____년 __월 __일	확인 유형 중심 연습

공식 원문이 아닌 창작 재구성입니다. 데이터·조건·모형 후보·분할을 보완했으며 실제 시험 점수·정답을 뜻하지 않습니다. 각 data 파일과 지문 조건을 따르십시오. 별도 해설 노트북·분석코드.py·출처 및 보완 명세를 제공합니다. 유의수준 5%·양측을 기본으로 하고 다중비교는 명시한 보정 절차를 적용합니다.

1. 질환 단계 예측

제공 자료: hepatitis.csv

hepatitis.csv의 Category는 0=정상, 1~3=질환 단계이며 x1~x6는 수치형 검사다. id mod 5=0이 보류 구간이다. 1번 전체는 같은 자료를 사용하며 리샘플링은 학습 폴드에서만 수행한다.

1-1. 결측 처리 대안 두 가지를 비교하고 품질·분포·공선성을 조사하시오. 타깃을 이용하지 않는 주성분 표현의 필요성과 해석 손실을 설명하시오.

1-2. 정상 대 질환의 이진 타깃을 만들고 원 학습과 무작위 오버/언더 표본 대안을 비교하시오. CV의 F1과 원 분포 보류 평가에서 precision·recall·F1·AUC를 보고하시오.

1-3. 질환군 1~3만 남겨 서로 다른 세 분류 모형을 같은 macro-F1 기준으로 비교하시오. 선택 모형의 보류 혼동행렬·정밀도·재현율과 특성 중요도 해석을 제시하시오.

2. 지하철 이용량과 날씨

제공 자료: subway.csv + weather.csv

subway.csv는 date·board·h05·h06·h07의 wide 표다. on/off를 합쳐 일별 이용량을 구성한다. weather.csv에는 일부 날짜 행 자체가 없다. 결측 강수값 0 대치는 원래 존재하는 날의 측정 결측에만 적용한다. 날짜가 누락된 날은 별도 플래그·학습 중앙값으로 처리한다. 2021~2022는 학습, 2023은 최종 시험이다.

2-1. 이용량 표를 변환·집계하고 날씨를 날짜로 일대일 결합하시오. 중복 키·미매칭 행을 검사하고 주말 여부를 생성하시오. 숫자 결측과 날짜 누락의 차이를 설명하시오.

2-2. 날씨·주말 특성으로 이용량을 예측하는 선형 및 트리 모형을 시간순 CV로 비교하시오. 정해진 최종 연도의 RMSE·MAE·R^2와 시간 의존성에 따른 한계를 보고하시오.

3. 공정·연착·시간 의존성

제공 자료: defect.csv + counts.csv + delay.csv + series.csv

defect.csv는 독립 추출한 A/B 공정의 불량률(연속 %)이며 paired가 아니다. counts.csv는 같은 노선에서 독립인 동일 시간창별 연착 건수다. delay.csv는 독립 사건의 line·minutes다. series.csv는 단일 시계열이다. 서로 별도 자료다.

3-1. 두 공정의 평균 불량률 차이를 평가하시오. 평균·표준편차·차이, 적절한 검정·가설·통계량·p-value·기각 여부를 제시하시오. 일별 비율과 이항 성공/실패 원시 건수의 차이를 설명하시오.

3-2. 연착 건수 자료가 하나의 일정률 발생 모형에 맞는지 평가하시오. 모수를 추정하고 관측·기대 빈도를 만들며 기대도수가 5 이상이 되도록 꼬리를 합치시오. 모수 추정 자유도·p-value·판정을 보고하시오.

3-3. 노선과 연착 구간(≤10, 10초과~20, >20분)의 관련성을 평가하시오. 구간 경계·관측/기대도수·가설·통계량·자유도·p-value·기각 여부를 제시하시오.

3-4. ACF·PACF를 설명하고 자료의 정상성을 진단하시오. ARMA 후보 (1,0),(2,0),(1,1),(2,1)을 학습 80%에서 AIC로 고르고, 시험 20%의 RMSE 및 선택 모형 잔차 10시차 진단을 제시하시오.